

# NUMERI REALI $\mathbb{R}$

$$d \in \mathbb{R}$$



$$n^o \in \mathbb{R}$$

ES 1

$$d = 21.37 \quad (\text{DOMANDA } \rightarrow \text{BASE ?})$$

$$\hookrightarrow (+21.37)_{10}$$

FORM. SCIENTIFICA

$$\hookrightarrow d = (+0.2137)_{10} \times 10^2$$

NON SEMPRE  
CERTA  
↑

ES 2

FORMA SCIENTIFICA ?

$$d = + (0.0045)_{10} \times 10^2$$

$$\hookrightarrow d = (+0.45)_{10} \times 10^{-2}$$

$p \begin{cases} = 2 \\ = -2 \end{cases}$   
↑  
ESPOLENTE  
DELLA  
BASE

$$d = \pm (0.d_1 d_2 d_3 \dots)_\beta \times \beta^p$$

CIFRE NUMERO

$$0 \leq d_1, d_2, \dots \leq \beta - 1 \quad d_1 \neq 0$$

POSSO AVERE INFINITA' DI CIFRE

\* NOTAZIONE POSIZIONALE :  $d = \pm (d_1 \cdot \beta^{-1} + d_2 \cdot \beta^{-2} + d_3 \cdot \beta^{-3} \dots)_\beta \times \beta^p$

MANTISSA

$$= \pm (M)_\beta \times \beta^p \quad 0 \leq d_i \leq \beta - 1 \quad d \neq 0$$

$$M = \sum_{i=1}^{\infty} d_i \cdot \beta^{-i}$$

PER IL NOSTRO  
CALCOLATORE SI  
DOVRANNO LIMITARE  
A UN NUMERO  
FINITO.

NUMERI FINITI : NUMERI CHE USANO I CALCOLATORI PK I NUMERI REALI SONO INFINITI

$$[\mathbb{F}]$$

↓  
SOTTOINSIEME DI  $\mathbb{R} \rightarrow \mathbb{F} \subset \mathbb{R}$

BASE ESPOENETI PIU' PICCOLI E GRANDI CHE SI POSSONO MEMORIZZARE

DEF :  $\mathbb{F}(\beta, \epsilon, \lambda, \omega)$  E' L'INSIEME DI  $n^o$  FINITO :

CARATTERIZZAZIONE

$$\beta \geq 2 \quad \epsilon \geq 1 \quad \lambda \geq 1 \quad \omega \geq 1$$

$$\{ \emptyset \} \cup \{ d \in \mathbb{R} ; d = \pm m_\epsilon \times \beta^p \text{ con } d_1 \neq 0, \lambda \leq p \leq \omega \}$$

$$m_\epsilon = \sum_{i=1}^{\epsilon} d_i \beta^{-i} \quad \tilde{d} \in \mathbb{F}$$

MANTISSA

ESEMPIO :  $\mathbb{F}(2, 3, -1, 2)$  VOGLIAMO CAPIRE SA QUANTI  $n^o$  E' FATTO L'INSIEME. I  $n^o$  SARANNO A 3 CIFRE

MANTISSA  $\rightarrow \tilde{d} = \pm (0.d_1 d_2 d_3)_2 \cdot 2^p \quad -1 \leq p \leq 2 \quad d_1 \neq 0$

$$= \pm (0.1d_2d_3)_2 \cdot 2^p$$

ORA POSSIAMO SCRIVERE TUTTI I NUMERI DI QUESTO INSIEME:

Segue:

$$\left. \begin{array}{l} 0.100 \\ 0.101 \\ 0.110 \\ 0.111 \end{array} \right\} \cdot 2^{-1} \cdot 2^0 \cdot 2^1 \cdot 2^2 \Rightarrow 33 \text{ ELEMENTI}$$

ORA VOGLIAMO VEDERLI SULL'ASSE REALE PER VEDERE COME SONO DISTRIBUITI:

↓

$$0.100 = 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 0 \cdot 2^{-3} = \frac{1}{2} = \frac{4}{8}$$

$$0.101 = 1 \cdot 2^{-1} + 0 \cdot 2^{-2} + 1 \cdot 2^{-3} = \frac{1}{2} + \frac{1}{8} = \frac{5}{8}$$

$$0.110 = 1 \cdot 2^{-1} + 1 \cdot 2^{-2} + 0 \cdot 2^{-3} = \frac{1}{2} + \frac{1}{4} = \frac{6}{8}$$

$$0.111 = 1 \cdot 2^{-1} + 1 \cdot 2^{-2} + 1 \cdot 2^{-3} = \frac{1}{2} + \frac{1}{4} + \frac{1}{8} = \frac{7}{8}$$

h<sup>3</sup> di mantisse

$$\frac{4}{8} \cdot 2^{-1} = \frac{4}{16}$$

$$\frac{4}{8} \cdot 2^0 = \frac{4}{8}$$

$$\frac{4}{8} \cdot 2^1 = \frac{4}{4}$$

$$\frac{4}{8} \cdot 2^2 = \frac{4}{2}$$

$$\frac{5}{8} \cdot 2^{-1} = \frac{5}{16}$$

$$\frac{5}{8} \cdot 2^0 = \frac{5}{8}$$

$$\frac{5}{8} \cdot 2^1 = \frac{5}{4}$$

$$\frac{5}{8} \cdot 2^2 = \frac{5}{2}$$

$$\frac{6}{8} \cdot 2^{-1} = \frac{6}{16}$$

$$\frac{6}{8} \cdot 2^0 = \frac{6}{8}$$

$$\frac{6}{8} \cdot 2^1 = \frac{6}{4}$$

$$\frac{6}{8} \cdot 2^2 = \frac{6}{2}$$


$$\frac{7}{8} \cdot 2^{-1} = \frac{7}{16}$$

$$\frac{7}{8} \cdot 2^0 = \frac{7}{8}$$

$$\frac{7}{8} \cdot 2^1 = \frac{7}{4}$$

$$\frac{7}{8} \cdot 2^2 = \frac{7}{2}$$

SCRIVIAMO SULL'ASSE REALE:  $\pm \frac{1}{3}$



CARATTERISTICHE DEI NUMERI

↳ ADDENSATI → VICINO ALLO ZERO

↳ LONTANI TRA LORO → LONTANI DALLA ZERO

STANDARD ANSI/IEEE 754 DEL 1985

↳ DETTA COME SONO I NUMERI FINITI IN BASE 2 SU CALCOLATORI.

↳ TIPO → EXTENDED (NON TRATTE ABNO) E BASIC

CHI È IF ?


IF (2, 24, -127, +128) **BASIC SINGLE** (32 BIT)

IF (2, 53, -1023, +1024) **BASIC DOUBLE** (64 BIT)

SINGLE E DOUBLE  
32 BIT R 64 BIT  
NUMERI FINITI  
DEVONO ESSERE USATI

TUTTI I N° FINITI

AREA DI MEMORIA 32 BIT



1° BIT

+ 0  
- 1 SEGNO

PER L'ESPONENTE  
[e]

MANTISSA

(NOTA : I N° SONO I BASE 2)  
SONO 23 PER d<sub>1</sub> E'  
SEMPRE 1.

0. d<sub>1</sub> d<sub>2</sub> ... → 1. d<sub>1</sub> d<sub>2</sub> ... , d<sub>t-1</sub>

t = 24

N° VICIN A ZERO

00 ~~~~ 0 = 0 → -127  
11 ~~~~ 1 = 255 → +128

RANGE ESPONENTI → PER RANGE MASSIMALE


DOUBLE

$$\begin{aligned} e &= p - 2 \\ p &= e + 2 \end{aligned}$$

FORMULE PER TROVARE L'ESPONENTE

???

ANALOGO DEL **DOUBLE** :



SEGNO

ESPONENTE  
[e]

MANTISSA


0 → -1023  
2047 → +1024 } RANGE ESPONENTE

(ANALISI TUTTO QUELLO CHE PUO' SUCCESSERE)  
 COMPUTAZIONE DA  $\mathbb{R}$  AD  $\mathbb{F}$

\* Floating Point?

DATO un n° REALE  $d$  COME SI PASSA AD un SUO RAPPRESENTANTE  
 $\tilde{d}$ . (0.1 in BASE 10 in BASE 2 HA una RAPPRESENTAZIONE PERIODICA)

Es IN BASE 10)



$\mathbb{F}(10, 5, -50, +49)$

DATO  $d = 0.345678 \cdot 10^0 \in \mathbb{R}$  ?  $\tilde{d} \in \mathbb{F}$

Domanda 1  $\rightarrow$  E' IN FORMA SCIENTIFICA ? (SI)

Domanda 2  $\rightarrow$  L'ESPOLENTE E' NEL RANGE ? (SI)  $-50 \leq p \leq 49$

Domanda 3  $\rightarrow$  MANTISSA  $t \leq 5$  ? (NO)

$\downarrow$   
 3  $\rightarrow$  TRONCAMENTO MANTISSA : TRONCHIAMO A 5 CIFRE  $\tilde{d} = 0.34567 \cdot 10^0$   
 $\hookrightarrow$  ARROTONDAMENTO MANTISSA : APPLICHIAMO LE FORMULE  
 (MIGLIORE DA FARE SE POSSIBILE)

$$\begin{array}{r} \overset{123456 \text{ POS.}}{0.345678} \\ \underline{\phantom{0.34567} + \frac{1}{2}} \\ 0.345683 \\ \tilde{d} = 0.34568 \cdot 10^0 \end{array}$$

Altro Esempio :

$$\begin{aligned} d &= 34.5678 \cdot 10^{49} \\ &\text{1 Form. Sc.} \quad \nearrow \text{ESPOLENTE NON IN RANGE} \\ &= 0.345678 \cdot 10^{51} \end{aligned}$$

NON RAPPRESENTABILE !

- 1) FORMA SCIENTIFICA
- 2) ESPOLENTE  $\rightarrow$  NO  $\rightarrow$  OVER FLOW

Altro Esempio:

$$\begin{aligned} d &= 0.00345678 \cdot 10^{-49} \\ &\text{1 Form. Sci.} \\ &= 0.345678 \cdot 10^{-51} \end{aligned}$$

- 1) FORMA SCIENTIFICA
- 2) ESPOLENTE  $\rightarrow$  NO  $\rightarrow$  UNDER FLOW  $\rightarrow$  NON SI BLOCCA MA

APPROSSIMATO A  
 CRASUAL UNDER FLOOR

# Altro Esempio:

PROBLEMA CHE RISOLVIAMO E' PASSARE DA  $\mathbb{R} \rightarrow \mathbb{F}$

ESEMPIO INIZIALE  $\mathbb{F}(2, 3, -2, 2)$

- 1° DOMANDA  $\rightarrow$  QUANTI BIT SI USANO PER MEMORIZZARLI?
- 2° SE CI DA  $d = (0.11011)_2 \cdot 2^{-2}$  CHI E'  $\tilde{d}$  CHE LO RAPPRESENTA IN MEMORIA?
- 3°  $d = (11.011)_2 \cdot 2^2$  CHI E'  $\tilde{d}$ ?

QUINDI CHIAMIAMO  $fl: \mathbb{R} \rightarrow \mathbb{F}$   $fl$  STA PER FLOAT

$d \rightarrow fl(d) = \tilde{d}$

$$fl(d) = \begin{cases} 0 \cdot \beta^0 & \text{se } d = 0 \\ \pm m_e \cdot \beta^p & \text{se } d \neq 0 \text{ e } \lambda \leq p \leq u \end{cases}$$

CON  $m_e$  2E PRIME E CIFRE DI  $m$


$\hookrightarrow$  CON  $m_e$   $\begin{cases} \text{PRIME E CIFRE DI } m \text{ (TRONCAMENTO)} \\ \text{PRIME E CIFRE DI } m + \frac{\beta}{2} \cdot \beta^{-(e+1)} \text{ (ARROTONDAMENTO)} \end{cases}$

\* SE  $p < \lambda, p > u$   $d$  NON E' RAPPRESENTABILE

IN BREVE: COME APPROSSIMARE UN N° REALE A UN N° FINITO PER IL NOSTRO CALCOLO (CHE PORTERA' A RISULTATI NON PROPRIO ESATTI).

## INTERPRETAZIONE GRAFICA DELLA NOSTRA SITUAZIONE:

SIANO  $x, y \in \mathbb{F}$  N° FINITI CONSECUTIVI (IN MEZZO NON CI SONO N° FINITI MA N° REALI)



IL FLOAT MOLONO DI  $d$  E'  $x$  E IL FLOAT ARROTONDANO  $d$  E'  $y$



$$f_{LT}(d) = x$$

↓  
TRANSITO

$$f_{LA}(d) = \begin{cases} x & \text{SE } d < \frac{x+y}{2} \\ y & \text{SE } d \geq \frac{x+y}{2} \end{cases}$$

## STANDARD ANSI/IEEE 754

→ ARRESTO L'ESECUZIONE

\* NaN : NOT A NUMBER (PER ES  $\sqrt{x}$  CON  $x < 0$ )

\* INF PER  $\infty$  (INF → INFORMAZIONI NON NUMERICA)

\* GRADUAL UNDERFLOW  
↳ ESECUZIONE VA AVANTI MA POTREBBE INTERRUPTORSI

\* ARROTONDAMENTO AI PARI → QUANDO CONVIENE  
ARROTONDAMENTO  
TRONCAMENTO

$$\begin{aligned} &\downarrow \\ &f_{AP} \begin{cases} x & \text{SE } d < \frac{x+y}{2} \\ \text{PARI}(x, y) & \text{SE } d = \frac{x+y}{2} \\ y & \text{SE } d > \frac{x+y}{2} \end{cases} \\ &\downarrow \\ &\text{ARROT. PARI} \end{aligned}$$

VISITA SITO PER QUESTE COSE!

**\* ES X CASA PER PROSSIMA VOLTA!!!**

SI MULARE DA INIZIO A FINE DI UN "DATO" DATO DALL'UTENTE  
E LO VUOLE STAMPARE A VIDEO

ESERCIZIO: SELEZIONO LO STANDARD ANSI/IEEE 754  
ABBIAMO 8 BIT (BASE 2) PER RAPPRESENTARE I NUMERI FINITI  
E PER LA PRECISIONE 1 PER SOLO, 3 ESPONENTI,  
2, PER MANTISSA



INPUT:  $d = -(13.9)_{10}$

↓  
INSERIRE SECONDO STANDARD (MEMORIZZARLO)

↓  
RAPPRESENTAZIONE

↓

DECONVILA → STAMPA

Base 2 → Base 10  
←